



Perbandingan Model U-NET dan F8CN untuk Semantic Segmentation

Self-Driving Car Project | Computer Vision & Deep Learning

Project Team Presentation | 2026

Daftar Isi

01

Pengenalan Tim

Anggota team dan peran dalam project

02

Dataset & EDA

Eksplorasi dataset road scene

03

Arsitektur Model

U-NET dan F8CN ResNet

04


Training & Evaluasi

Training, Optuna tuning, dan perbandingan

05

Kesimpulan



Ringkasan hasil dan rekomendasi



01

Pengenalan Tim

- Ridwan Pionner Panjaitan
- Dwi Adi Leggana putra
- Gunandi Rismanda
- Felim



Anggota Team Project



Ridwan Pioneer Panjaitan
Gunadi Rismananda
U-NET

- U-NET Model Development
- F8CN Training Implementation
- Dataset Preparation & EDA
- Video Processing Pipeline



Felim
Dwi Adi Leggana Putra
F8CN

- F8CN dengan Optuna Tuning
- Hyperparameter Optimization
- Evaluation & Visualization
- Model Benchmarking

Project Overview

Task: Multi-Class Semantic Segmentation

Domain: Self-Driving Car Road Scenes

Dataset: Local City Road Scene Dataset

Classes: 12 kelas (Sky, Building, Pole, Road, Pavement, Tree, SignSymbol, Fence, Car, Pedestrian, Bicyclist, Unlabelled)

Models: U-NET & F8CN ResNet50


Framework: PyTorch + Optuna

GPU: RTX 5070 Ti, T4, L4

02


Dataset & EDA

Eksplorasi dataset road scene



■ Sky ■ Building ■ Road ■ Sidewalk ■ Fence

Dataset Road Scene



Dataset: Local Cityt Road Scene Dataset

Train Images: 367 paired samples

Test Images: 101 paired samples

Validation: 73 samples (20% dari train)

Image Size: 256 x 512 (H x W)

Format: PNG dengan mask diskrit 0-11

Classes: 12 kelas semantic

ID	Class	ID	Class	ID	Class	ID	Class
0	Sky	3	Road	6	SignSymbol	9	Pedestrian
1	Building	4	Pavement	7	Fence	10	Bicyclist
2	Pole	5	Tree	8	Car	11	Unlabelled

Exploratory Data Analysis

Data Quality Check

- 367 train images dengan label yang sesuai
- 31 train image tanpa label (di-exclude)
- 0 train label tanpa image
- Final split: 294 train / 73 val / 101 test
- Semua image diresize ke 256x512
- Mask label: diskrit integer 0-11

Data Augmentation

- **Flip:** Horizontal flip prob = 0.5
- **Color Jitter:** prob = 0.8
- **Brightness:** ± 0.20
- **Normalization:** ImageNet mean/std
- **Class Weighting:** power=0.5
- **Min/Max Weight:** 0.5 / 8.0



Sample: Input Image dan Ground Truth Mask


Key Insight

Dataset memiliki class imbalance yang signifikan. Class weighting dan augmentasi diperlukan untuk menangani ketidakseimbangan ini dan mencegah model bias terhadap class mayoritas.

03


Arsitektur Model

U-NET dan F8CN ResNet untuk semantic segmentation



Arsitektur U-NET

Working of U-Net Architecture



U-NET Encoder-Decoder Architecture

Encoder (Contracting Path)

- Convolutional layers + Max Pooling
- Mengekstrak feature maps hierarkis
- Base channels: 32

Decoder (Expanding Path)

- Up-convolution + Skip Connections
- Menyambungkan feature encoder ke decoder
- Output: 12-class segmentation map

Skip Connections

- Menjaga detail spasial dari input
- Kritis untuk boundary precision

Input: 256 x 512 x 3 (RGB) | **Output:** 256 x 512 x 12 (Classes) | **Loss:** CE + Dice | **Optimizer:** Adam (lr=1e-4)

Device: NVIDIA GeForce RTX 5070 Ti | **Framework:** PyTorch 2.10.0+cu128 | **AMP:** Enabled

Arsitektur F8CN (Fully Convolutional Network)

Backbone: ResNet50


- Pre-trained on ImageNet (DEFAULT weights)
- Transfer learning untuk feature extraction
- 50-layer deep residual network

FCN Head

- Mengganti FC layers dengan conv layers
- Upsampling untuk dense prediction
- Pixel-wise classification 12 kelas

Fully Convolutional

- Menerima input arbitrary size
- Output spatial map sesuai input



FCN Architecture dengan Skip Connections

Model: torchvision.models.segmentation.fcn_resnet50 | **Weights:** DEFAULT (ImageNet pre-trained)

Input: 256 x 256 x 3 (RGB) | **Output:** 12-class segmentation map

Loss: CrossEntropyLoss | **Metrics:** DiceScore, MeanIoU (torchmetrics)

Device: T4 GPU (training) / L4 GPU (Optuna) | **Accelerator:** HuggingFace Accelerator (mixed precision)

04

Hyperparameter tuning

Optuna Tuning



Summary hasil training dengan Optuna -U- Net

Optuna adalah framework hyperparameter optimization yang menggunakan Sampler TPESampler untuk menemukan kombinasi hyperparameter terbaik secara otomatis dengan direction minimize.

Parameter	Search Space	Type
Learning Rate	1e-5 - 1e-2	Log Uniform
Optimizer	Adam / AdamW / SGD /RMSProp	Categorical
Momentum	0.85 - 0.95	Uniform
Weight Decay	1e-6 - 1e-2	Log Uniform
n_trials	10	Fixed

Best Parameters

Learning Rate: 0.0010370844668954541
Optimizer: Adam
Momentum: 0.9
Weight Decay: 0.0048696409415209
Best Score: 2.2366720835367837


Summary Result Hyperparameter Tuning dengan Optuna - U-Net

Trial	Status	Optimizer	Learning rate	Weight Decay	Momentum	Val loss
1	COMPLETE	AdamW	0.000184	0.000004	-	2.7697
2	COMPLETE	AdamW	0.000108	0.007579	-	3.1570
3	COMPLETE	Adam	0.000329	0.000126	-	2.5981
4	PRUNED	Adam	0.000120	0.000269	-	3.2045
5	PRUNED	SGD	0.002363	0.000017	0.8637	2.8161
6	PRUNED	Adam	0.000114	0.004338	-	3.2825
7	PRUNED	AdamW	0.000849	0.000849	-	3.1824
8	COMPLETE	Adam	0.001037	0.004870	-	2.2367
9	PRUNED	SGD	0.000457	0.000012	0.9660	3.3211
10	PRUNED	Adam	0.000984	0.001281	-	3.1858

Best Result :

- Optimizer : Adam
- learning rate : 0.001037
- weight decay : 0.004870
- score : 2.2367

Visualize Hyperparameter Tuning dengan Optuna - U-Net



Hyperparameter Tuning dengan Optuna - F8CN

Optuna adalah framework hyperparameter optimization yang menggunakan Sampler TPESampler untuk menemukan kombinasi hyperparameter terbaik secara otomatis dengan direction maximize.

Parameter	Search Space	Type
Learning Rate	1e-5 - 1e-2	Log Uniform
Optimizer	Adam / AdamW / SGD	Categorical
Momentum	0.85 - 0.95	Uniform
Beta1	0.9 - 0.99	Uniform
Beta2	0.99 - 0.999	Uniform
Weight Decay	1e-6 - 1e-2	Log Uniform
n_trials	5	Fixed

Best Parameters

Learning Rate: 8.17949947521167e-05

Optimizer: Adam

Beta1: 0.9125544474586837

Beta2: 0.992629301836817

Weight Decay: 2.9204338471814107e-05

Best Score: 0.6484393338744456

Summary Result Hyperparameter Tuning dengan Optuna - F8CN



Trial	Status	Optimizer	Learning rate	Beta 1	Beta 2	Weight Decay	Momentum	Score (0.5 * Dice + 0.4 * IOU - 0.1 * loss)
1	COMPLETE	Adam	0.0001329291894316216	0.9140395068302583	0.9905227525095138	0.0029154431891537554	-	0.6218755040031213
2	COMPLETE	SGD	0.0006358358856676254	-	-	5.415244119402541e-06	0.9332442640800421	0.6218755040031213
3	COMPLETE	Adam	8.17949947521167e-05	0.9125544474586837	0.992629301836817	2.9204338471814107e-05	-	0.6484393338744456
4	COMPLETE	Adam	0.00023345864076016249	0.9041805371447998	0.9954679036671129	4.809461967501575e-06	-	0.6348092473470248
5	COMPLETE	AdamW	1.5673095467235405e-05	0.9087904902605746	0.9961580972386094	5.762487216478604e-05	-	0.5828120248822065

Best Result :

- Optimizer : Adam
- learning rate : 8.17949947521167e-05
- beta1 : 0.9125544474586837
- beta2 : 0.992629301836817
- weight decay : 2.9204338471814107e-05
- score : 0.6484393338744456

Visualize Hyperparameter Tuning dengan Optuna - F8CNt


Optuna Hyperparameter Tuning Results — F8CN Resnet



05

Training & Evaluasi

Training, Optuna tuning, dan evaluasi model



Konfigurasi Training U-NET

Parameter	Value
Epochs	100 (dengan early stopping)
Batch Size	32 (Physical = Effective)
Learning Rate	1e-4
Base Channels	32
Loss Function	CE Loss (1.0) + Dice Loss (1.0)
Optimizer	Adam
AMP (Mixed Precision)	Enabled (hemat VRAM)
Early Stopping	Patience = 5 epochs
Validation Ratio	20% dari training set

Notes: Training dilakukan pada NVIDIA GeForce RTX 5070 Ti dengan PyTorch 2.10.0+cu128. AMP (Automatic Mixed Precision) diaktifkan untuk efisiensi memori. Class weighting digunakan untuk menangani imbalance dengan power=0.5, min=0.5, max=8.0.

Konfigurasi Training F8CN

Parameter	Value
Epochs	50 (dengan early stopping patience=5)
Batch Size	4
Loss Function	CrossEntropyLoss
Optimizer	Adam
Metrics	DiceScore, MeanIoU (torchmetrics)
Accelerator	HuggingFace Accelerator (mixed precision)
Score Formula	$0.5 * vl_dice + 0.4 * vl_iou - 0.1 * vl_loss$

Score Formula Breakdown

Score = 0.5 x Validation Dice + 0.4 x Validation IoU - 0.1 x Validation Loss

Formula ini memberikan bobot tertinggi pada Dice Score (50%) dan IoU (40%), sambil mengurangi penalty dari loss (10%). Tujuannya adalah memaksimalkan segment quality sambil menjaga generalisasi.

Hasil Training U-NET

Training Configuration:

- Training berlangsung selama **100 epochs** dengan early stopping (patience=5)
- Best model disimpan berdasarkan validation metric terbaik
- Training pada **NVIDIA GeForce RTX 5070 Ti** dengan AMP enabled
- Evaluasi menggunakan metrik: **mIoU, F1-Score, Dice Score, Confusion Matrix**

Epochs

100

Batch Size

32

Learning Rate

1e-4

Loss

CE + Dice

Training Insight: U-NET dilatih dari scratch dengan arsitektur custom. Kombinasi loss CE + Dice membantu menangani class imbalance. AMP (Automatic Mixed Precision) mengurangi penggunaan VRAM hingga -40% tanpa mengorbankan akurasi, memungkinkan batch size 32 pada GPU 8GB.

Hasil Training F8CN

Training Configuration:

- Training berlangsung selama **50 epochs** dengan early stopping (patience=5)
- Best trial dari Optuna: **Score = 0.6484**
- Metrics: Dice Score, MeanIoU, Validation Loss (monitored per epoch)
- Device: **T4 GPU** (training) / **L4 GPU** (Optuna tuning)

Best Score

0.6484

Epochs

100

Batch Size

4

Optuna Trials

5

Training Insight: F8CN dengan pre-trained ResNet 50 backbone menunjukkan konvergensi yang lebih cepat dibanding U-NET (training dari scratch). Optuna berhasil menemukan learning rate optimal ($8.18e-05$) yang lebih kecil dari default, mengindikasikan bahwa fine-tuning pre-trained model memerlukan update yang lebih halus. Score tertinggi 0.6484 dicapai dengan kombinasi Adam optimizer dan weight decay minimal ($2.92e-05$).

Evaluasi Model – Metrik Perbandingan

Metrik	U-NET	F8CN	Winner
mIoU	0.5550	0.8685	F8CN
Dice Score	0.6658	0.6957	F8CN
F1-Score	0.6658	0.7157	F8CN
Pixel Accuracy	0.8164	0.9137	F8CN
Training Loss	CE + Dice	CrossEntropy	–
Training Epochs	100 epochs	100 epochs	F8CN
Convergence	Pelan (scratch)	Cepat (pre-trained)	F8CN
GPU Memory	RTX 5070 Ti	T4	–


Catatan: Perbandingan yang jelas adalah F8CN lebih cepat konvergen karena transfer learning, sementara U-NET menawarkan fleksibilitas arsitektur yang lebih tinggi.

Perbandingan Arsitektur & Performa

Aspek	U-NET	F8CN (ResNet50)
Arsitektur	Encoder-Decoder + Skip Connections	ResNet50 Backbone + FCN Head
Pre-trained	Tidak (from scratch)	Ya (ImageNet weights)
Parameter Count	~31M (base=32)	~23M (ResNet50)
Input Size	256 x 512	256 x 256
Training Speed	Lebih lambat (100 epoch)	Lebih cepat (100 epoch)
Flexibilitas	Tinggi (custom channels)	Sedang (fixed backbone)

Insight: U-NET menawarkan kontrol penuh atas arsitektur (base channels, depth) namun memerlukan training lebih lama. F8CN dengan ResNet50 pre-trained mempercepat konvergensi secara signifikan melalui transfer learning.

Visualisasi Hasil Prediksi – U-Net




Color Mapping (12 Classes):

Sky=Black, Building=Purple, Pole=Yellow, Road=Blue, Pavement=Pink, Tree=Green

SignSymbol=DarkGreen, Fence=Brown, Car=Yellow, Pedestrian=Red, Bicyclist=Orange, Unlabelled=Dark

Qualitative Analysis: Visualisasi menunjukkan perbandingan segmentasi antara U-NET dan F8CN. Kedua model berhasil mengidentifikasi class utama (Road, Car, Tree) dengan baik. Perbedaan terlihat pada boundary precision dan handling class minoritas (Sign Symbol, Pole).

Visualisasi Hasil Prediksi – F8CN




Color Mapping (12 Classes):

Sky=Dark Purple, Building=Purple, Pole=Brown, Road=Muted Blue, Pavement=Deep Violet, Tree=Dark Green

SignSymbol=Dark Green, Fence=Brown, Car=Light Green, Pedestrian=Moss green, Bicyclist=Yellow, Unlabelled=Dark

Qualitative Analysis: Visualisasi menunjukkan perbandingan segmentasi antara U-NET dan F8CN. Kedua model berhasil mengidentifikasi class utama (Road, Car, Tree) dengan baik. Perbedaan terlihat pada boundary precision dan handling class minoritas (Sign Symbol, Pole).

Video Testing & Demo



Video: nD_6.mp4 dengan Segmentation Overlay

Video Processing Pipeline

- **Input:** nD_6.mp4 (real-world driving scene)
- **Output:** nD_6_result.mp4
- **Overlay Alpha:** 0.62 (balance visibility)
- **Frame Processing:** Per-frame inference
- **Pipeline:** Read → Preprocess → Infer → Overlay → Write
- **Interface:** Gradio untuk interactive testing
- **Real-time:** Inference pada setiap frame video

Demo Insight: Video testing menunjukkan kemampuan model untuk melakukan real-time semantic segmentation pada scene bergerak. Overlay dengan alpha=0.62 memberikan keseimbangan antara visibilitas asli video dan informasi segmentasi. Gradio interface memungkinkan testing interaktif oleh user.

Gambar Testing & Demo



Gambar testing dengan F8CN





Gambar testing dengan U-NET

06

Kesimpulan & Rekomendasi

Ringkasan hasil dan saran pengembangan



Kesimpulan



U-NET: Arsitektur Custom

Efisien untuk dataset kecil dengan training dari scratch. Fleksibilitas arsitektur tinggi memungkinkan eksplorasi berbagai konfigurasi.



F8CN: Transfer Learning

Leverage pre-trained ResNet50 untuk konvergensi lebih cepat. Optuna tuning menghasilkan score terbaik 0.6484 dengan hyperparameter optimal.



Optuna: Hyperparameter Tuning

Automated hyperparameter optimization dengan Bayesian search. Menemukan learning rate optimal $8.18e-05$ untuk F8CN yang lebih kecil dari default.



Real-World Application

Kedua model berhasil melakukan multi-class semantic segmentation pada video real-world driving scene dengan overlay visualization.

Overall: F8CN dengan Optuna tuning menunjukkan hasil terbaik (score=0.6484) dengan konvergensi lebih cepat. U-NET menawarkan fleksibilitas arsitektur yang lebih tinggi untuk eksplorasi custom. Kedua model valid untuk aplikasi self-driving car semantic segmentation.

Rekomendasi

1. Dataset Enhancement

Perluas dataset dengan lebih banyak variasi kondisi: malam hari, hujan, kabut, dan berbagai kondisi cuaca lainnya untuk meningkatkan robustness model.

2. Model Architecture

Eksplorasi arsitektur hybrid (U-NET + pre-trained backbone seperti ResNet/ EfficientNet) untuk menggabungkan fleksibilitas U-NET dengan kekuatan transfer learning.

3. Training Optimization


Gunakan learning rate scheduler (Cosine Annealing, ReduceLROnPlateau) untuk kedua model. Tingkatkan n_trials Optuna menjadi 50-100 untuk eksplorasi yang lebih luas.

4. Deployment

Optimasi model dengan TensorRT/ONNX untuk real-time inference pada edge device. Quantization untuk mengurangi model size dengan minimal accuracy loss.

5. Future Work

Eksplorasi instance segmentation untuk deteksi objek individual. Integrasi dengan object detection pipeline untuk sistem self-driving yang lebih komprehensif.



Objects
3/02

X,Y
1400/1200



00:00:00



Terima Kasih

Questions & Discussion

Self-Driving Car Semantic Segmentation Project
U-NET vs F8CN | Computer Vision & Deep Learning